

SURVEILLANCE ACOUSTIQUE D'UNE RABOTEUSE INDUSTRIELLE COMMENT DÉTECTOR DES ANOMALIES

GRÂCE AU SON

**Anthony Deschênes, Rémi Georges, Cem
Subakan, Michael Morin**

21 mars 2025



Offre de stage de premier cycle

- Cet été
- Continuité du projet présenté aujourd’hui:
 - Collecte de données
 - Surveillance acoustique
 - Maintenance predictive
- Si intéressé, contacter:
 - anthony.deschenes@ift.ulaval.ca
 - remi.georges@sbf.ulaval.ca



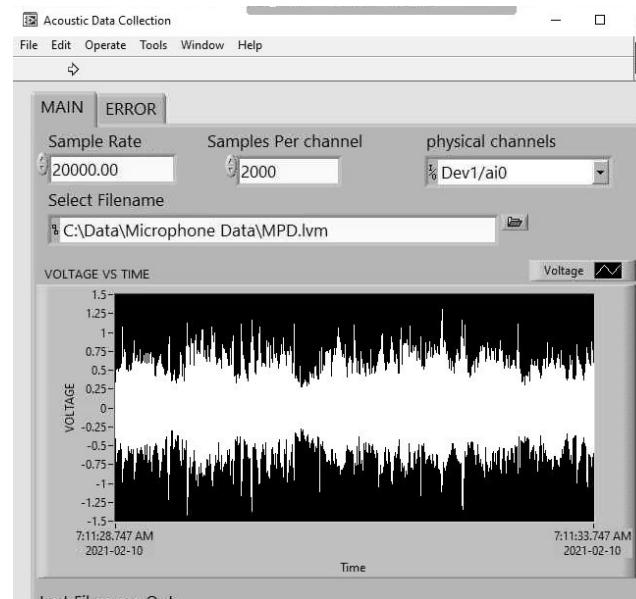
Mise en contexte

- Raboteuse industrielle
- Déetecter des anomalies/problems grâce au son
 - Inspiré du fait que les opérateurs expérimentés utilisent le son pour détecter certains problèmes



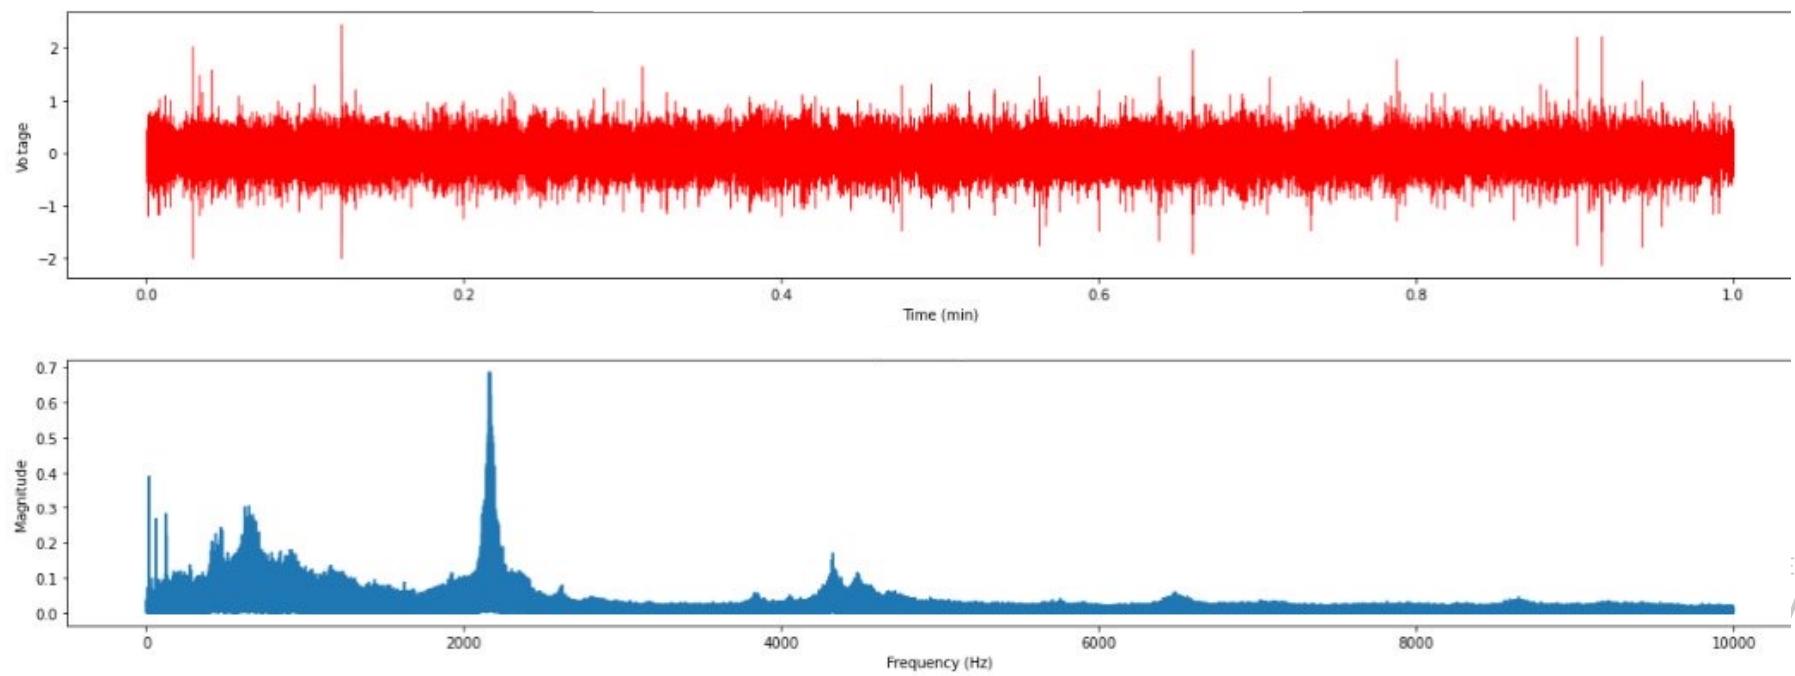
Traitement de signal

- Comment gérer des signaux audio?
 - Longueur possiblement variable
 - Signaux bruts difficilement interprétables



Transformée de Fourier

- Donne les fréquences présentes dans le signal
 - Ne donne pas l'aspect temporel

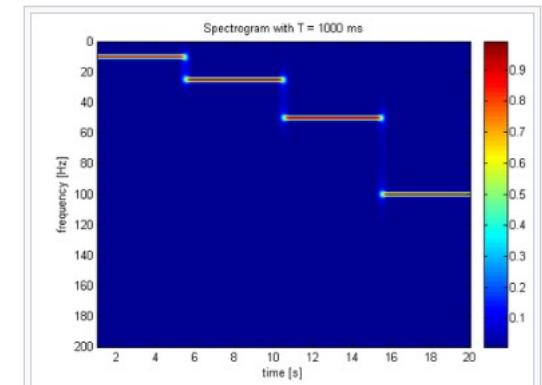
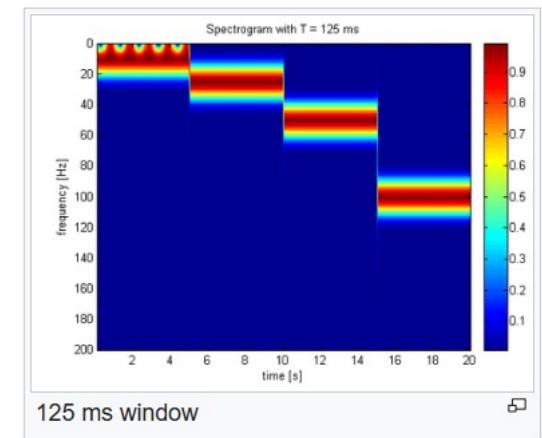
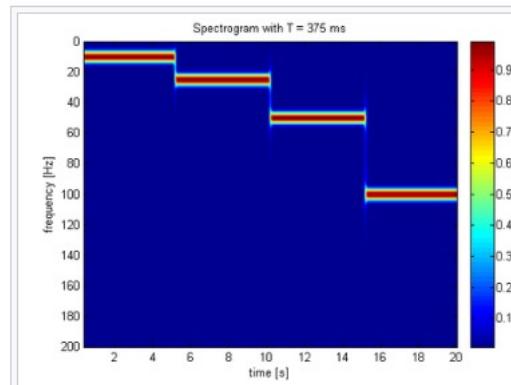
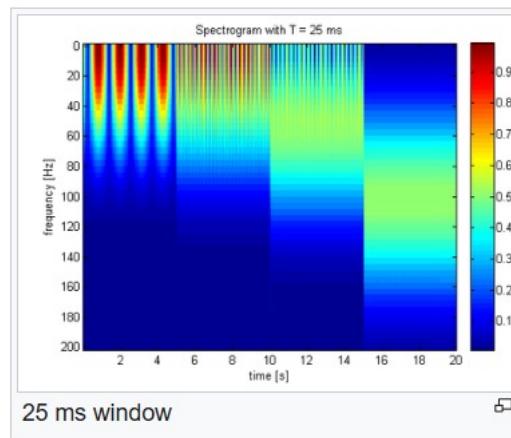


Short Time Fourier Transform

- Calcule des transformées de Fourier sur une fenêtre de temps
 - Taille de la fenêtre

$$x(t) = \begin{cases} \cos(2\pi 10t) & 0 \text{ s} \leq t < 5 \text{ s} \\ \cos(2\pi 25t) & 5 \text{ s} \leq t < 10 \text{ s} \\ \cos(2\pi 50t) & 10 \text{ s} \leq t < 15 \text{ s} \\ \cos(2\pi 100t) & 15 \text{ s} \leq t < 20 \text{ s} \end{cases}$$

Then it is sampled at 400 Hz. The following spectrograms were produced:



Problèmes avec les Short Time Fourier Transforms

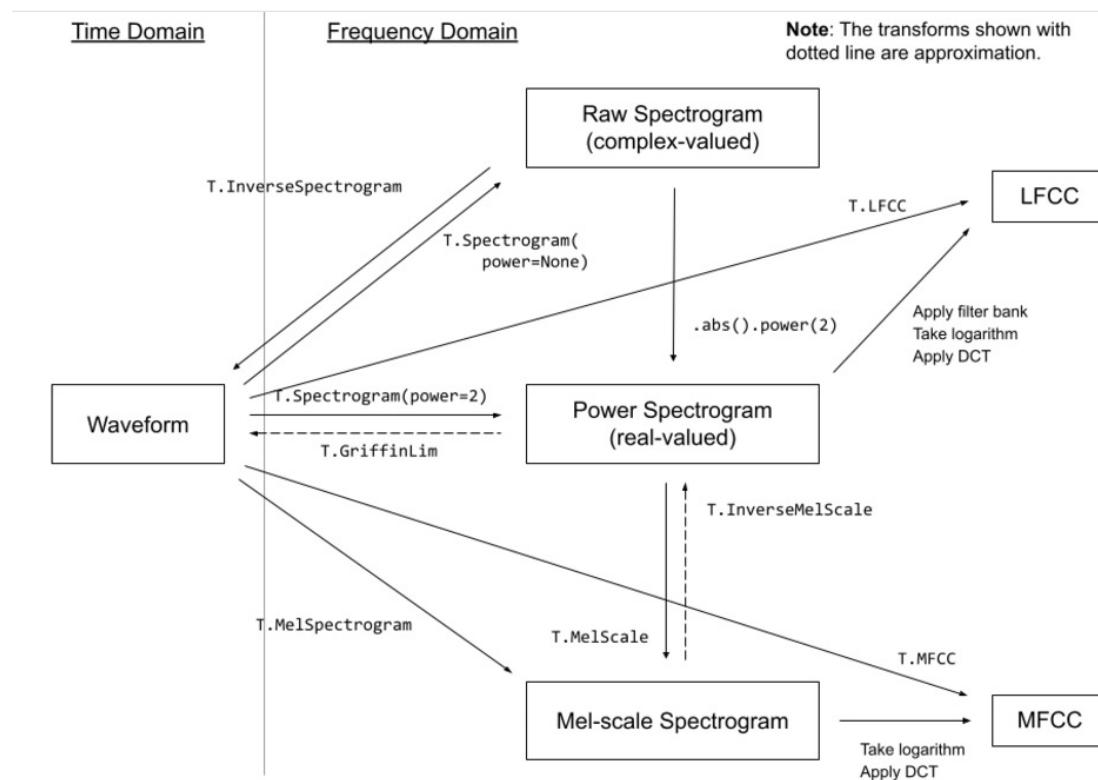
- Souvent assez volumineux
 - Beaucoup de paramètres en entrée
 - Mais permet la reconversion vers le signal brut
- Linéaire
 - L'oreille humaine ne fonctionne pas de façon linéaire
 - <https://onlinetonegenerator.com/>
 - Facile de différencier 500Hz et 1000Hz
 - Difficile de différencier 10 000hz et 10 500Hz
- Mel-Scale
 - Linéaire du point de vue de l'oreille humaine

Spectrogramme de MEL

- <https://notesbylex.com/mel-spectrogram>
- Paramètres principaux:
 - Taille de la fenêtre
 - Nombre de MEL bin
- La couleur représente des décibels (log-scaled)
- Plus près de l'oreille humaine
- Réduit la taille de l'entrée par rapport à une Short Time Fourier Transform
 - Dans mon cas passe de 400 000 à 32 000!

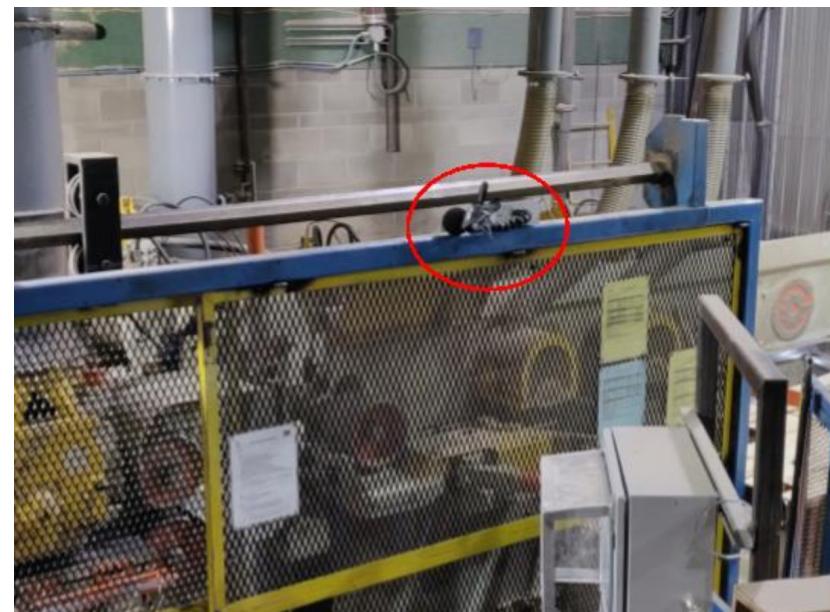
Mais encore!

- <https://pytorch.org/audio/master/transforms.html>



Données

- Enregistrements audios de 2019 à 2021 d'une raboteuse industrielle Gilbert chez GDS Matane
 - FPIInnovations
 - Environ 7 700
 - 105 anomalies identifiée par des experts
 - Blocage
 - Planche cassée
 - Planche d'épaisseur irrégulière
 - Segments de 10 secondes

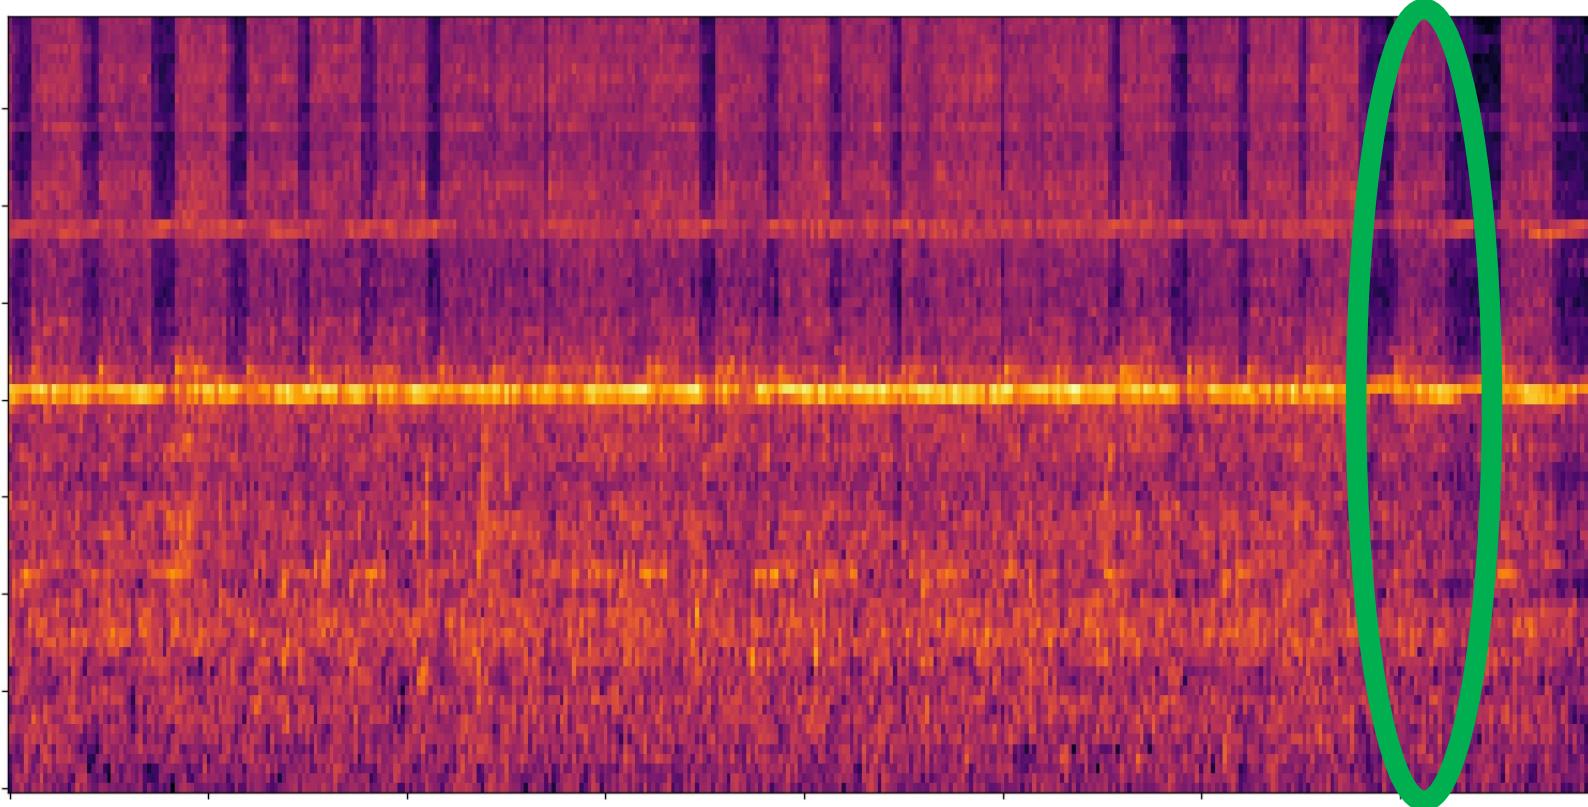


Données

TABLE I
DATASET DESCRIPTION WITH THE NUMBER OF RECORDING PER BOARD
TYPE AND THE TOTAL NUMBER OF ANOMALIES PER SET

	# 2×3	# 2×4	# 2×6	# Anomalies
Training set	90	1897	2340	0
Evaluation set	0	0	3235	105

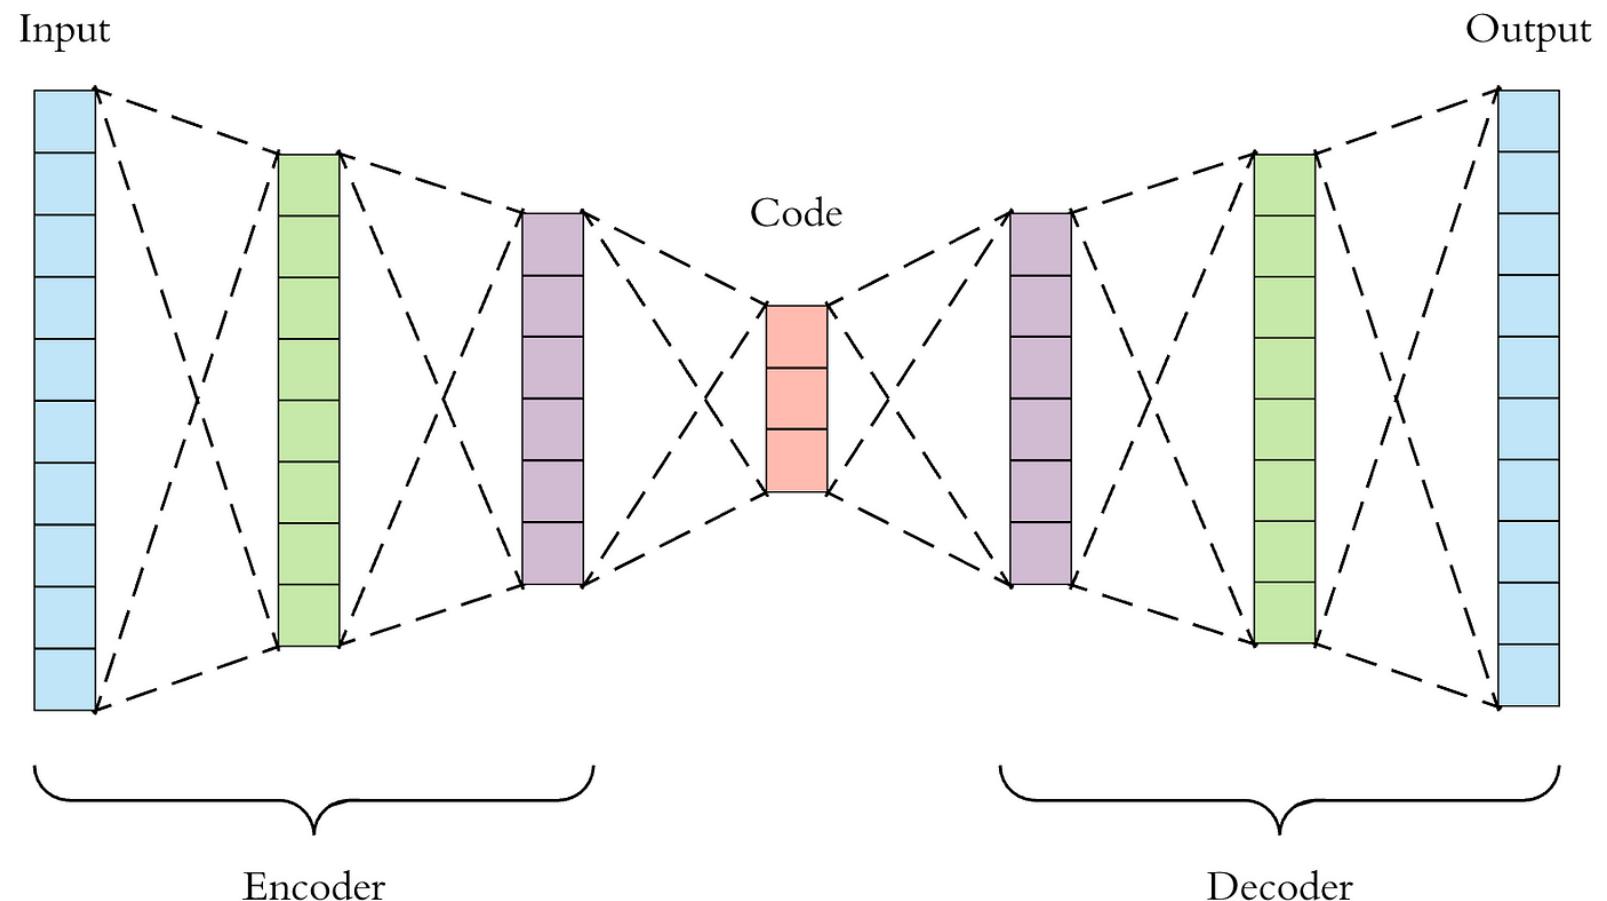
Exemple d'un Mel-Spectogram d'un enregistrement



Méthodologie

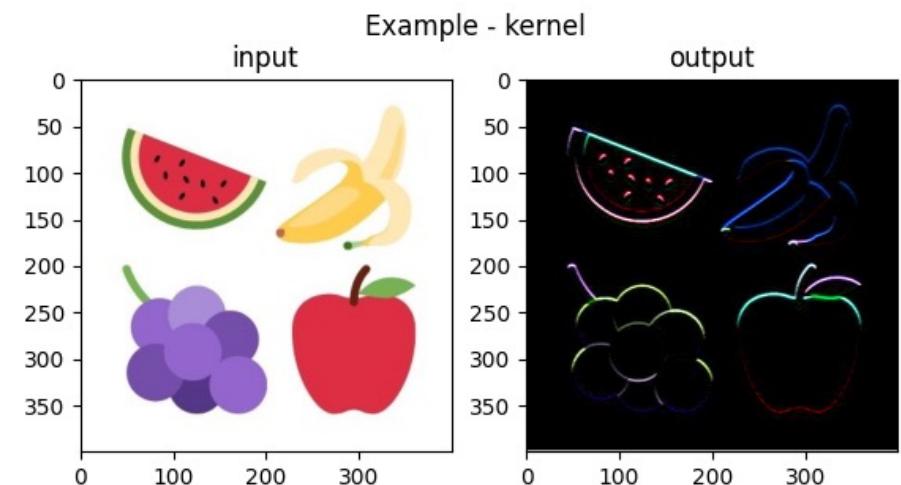
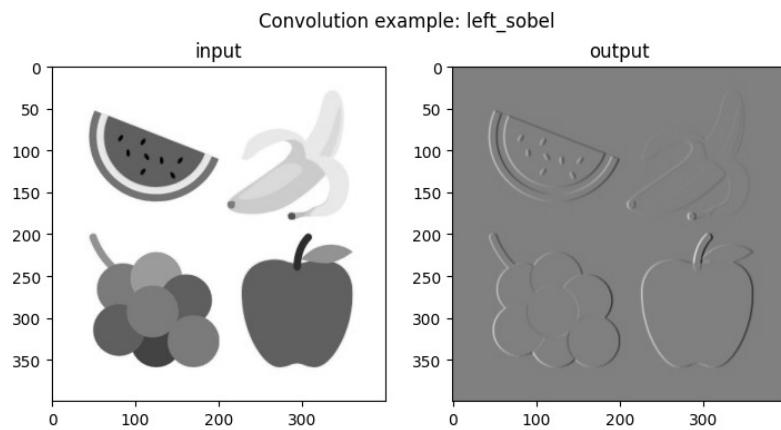
- Apprentissage non-supervisé pour détecter ces anomalies
 - Réseaux de neurones
 - Convolutionnal AutoEncoder (CAE)
 - Trouver une représentation standard du son d'une raboteuse
- Comparaison avec des approches classiques de détection d'anomalies
 - Forêt d'isolement
 - OneClass SVM
- Amélioration d'un modèle de la littérature

AutoEncoder



Convolutional AutoEncoder

- Même principe, sauf qu'on utilise des fenêtres de convolution



Modèles de comparaison

- CAE de Duman*
 - 22 couches
- Forêt d'isolement
- OneClass SVM
- AutoEncoder Baseline du dernier DCASE

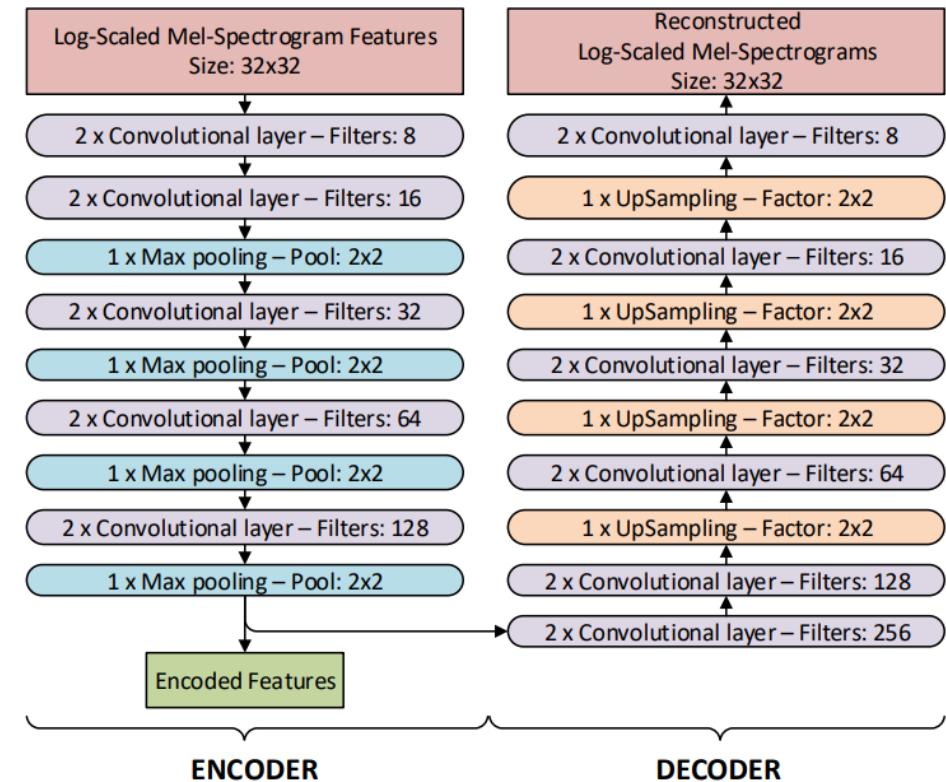


Fig. 2: Convolutional Autoencoder Architecture

* Duman, T. et al.. (2020). Acoustic anomaly detection using convolutional autoencoders in industrial processes

Modèles proposés

- Ajout de skip connections
 - Skip-CAE
- Ajout de mécanismes d'attention (Transformer)
 - Skip-CAE-Transformer
- Deux modèles séparés pour tester l'impact de chaque modification

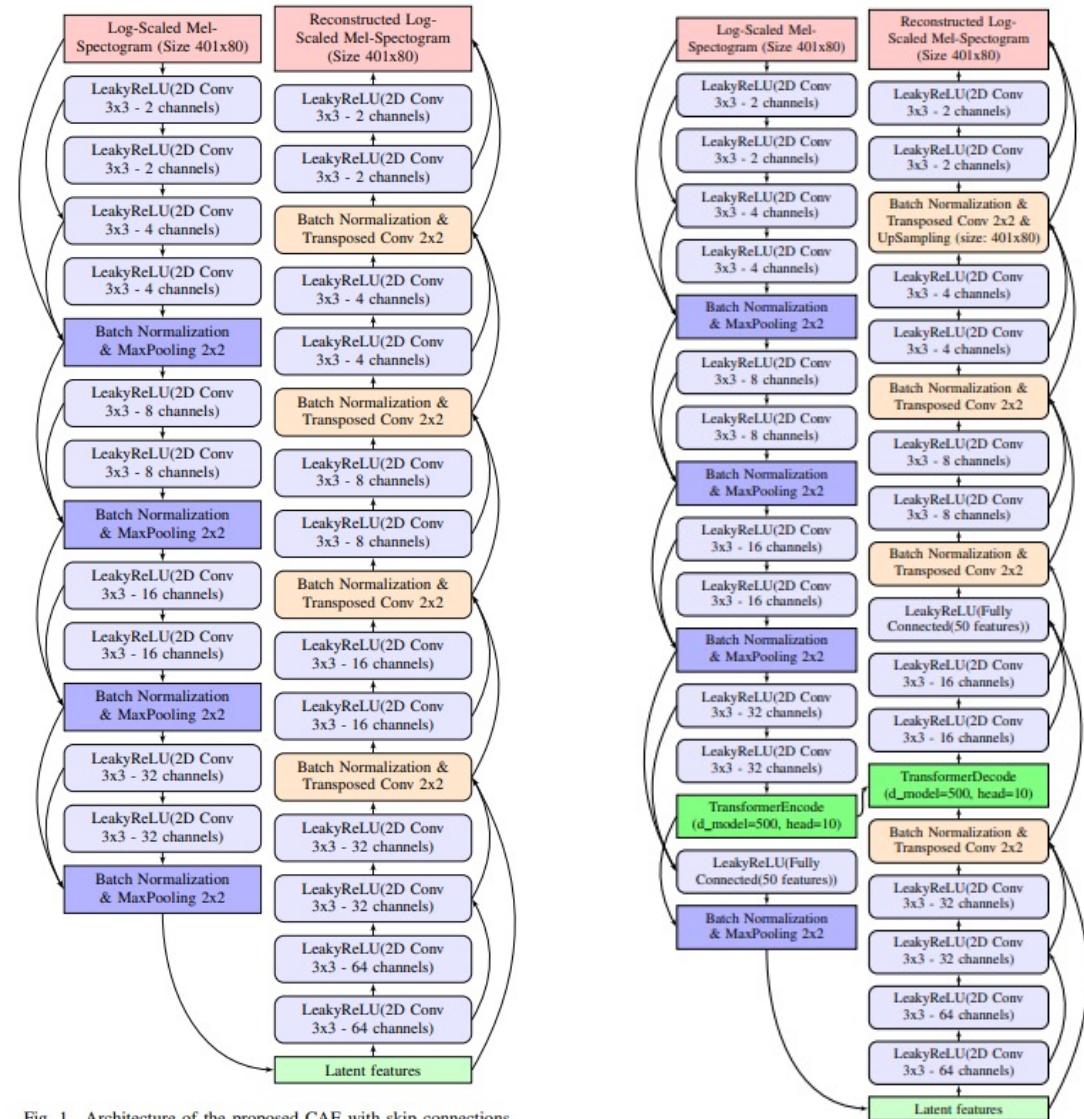
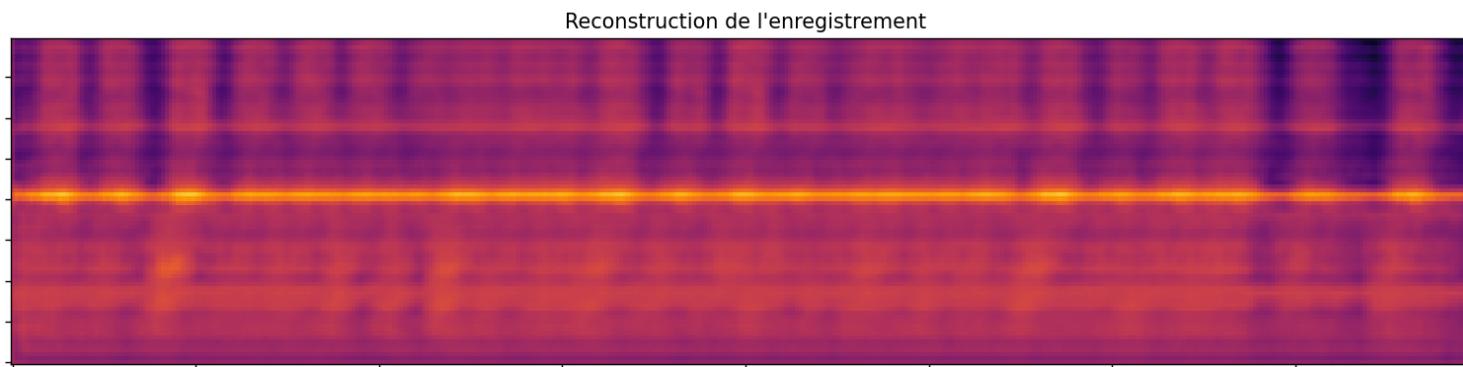
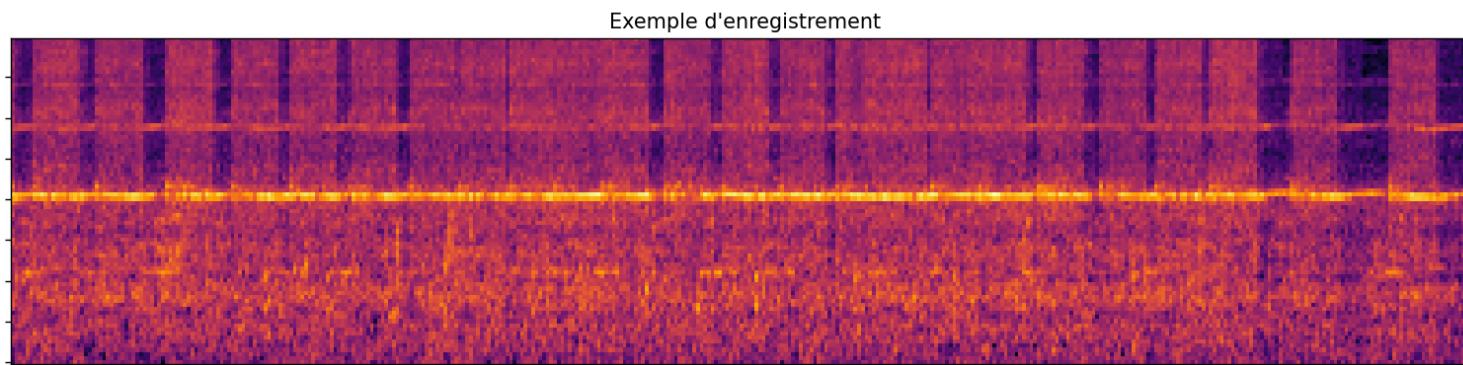
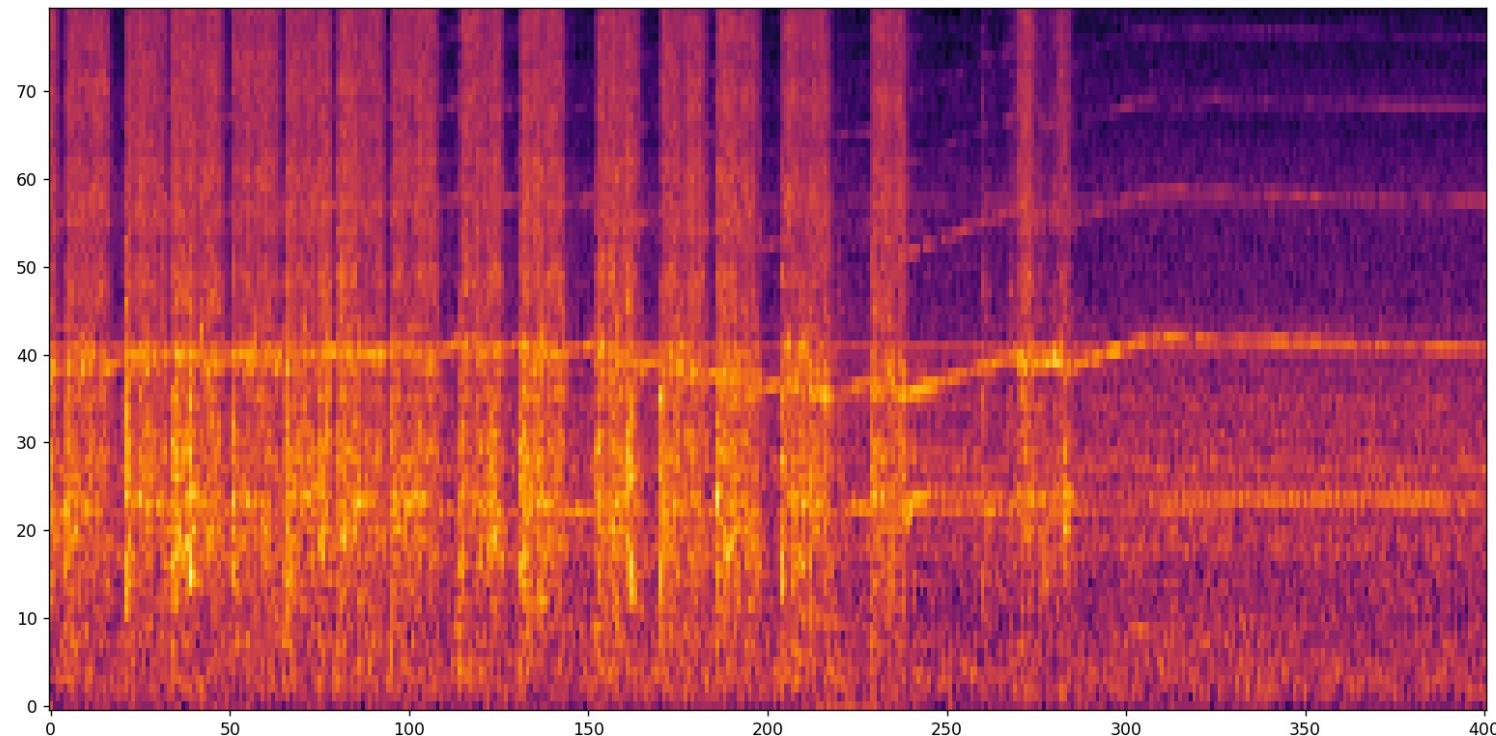


Fig. 1. Architecture of the proposed CAE with skip connections

Reconstruction de la donnée (Transformer)

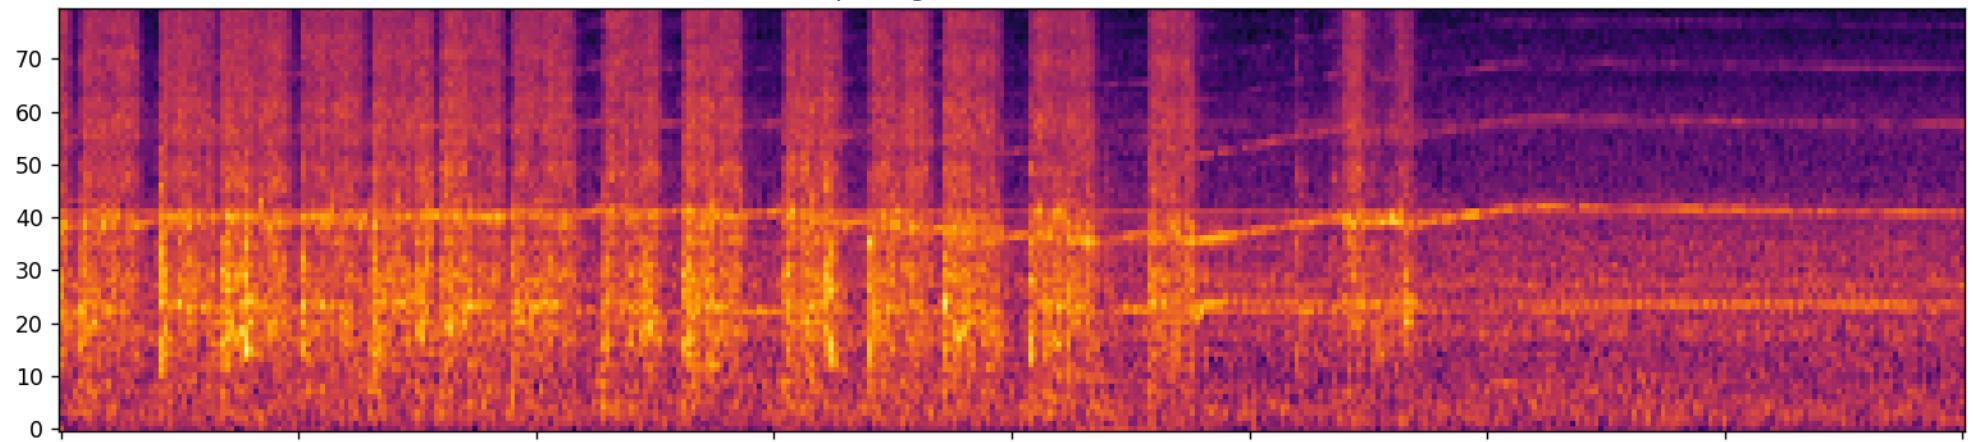


Exemple d'un enregistrement anormal (Bois cassé)

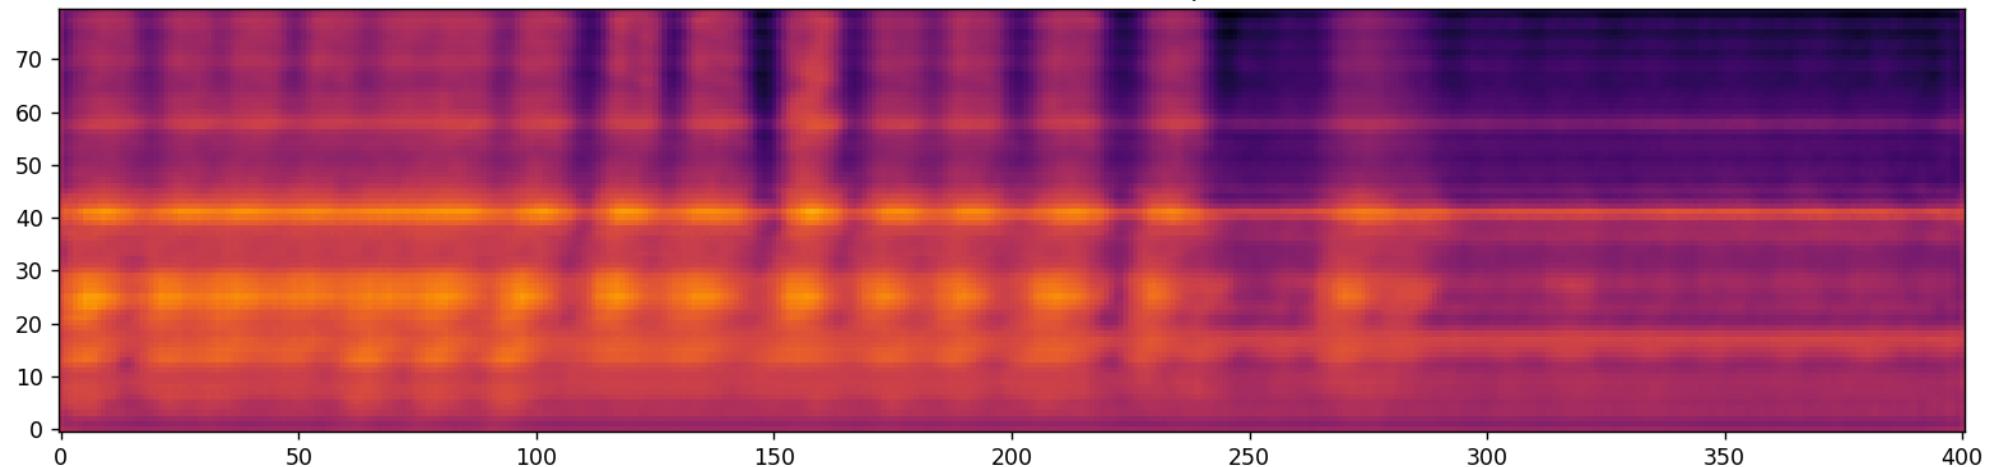


Spectrogram de MEL Anormal

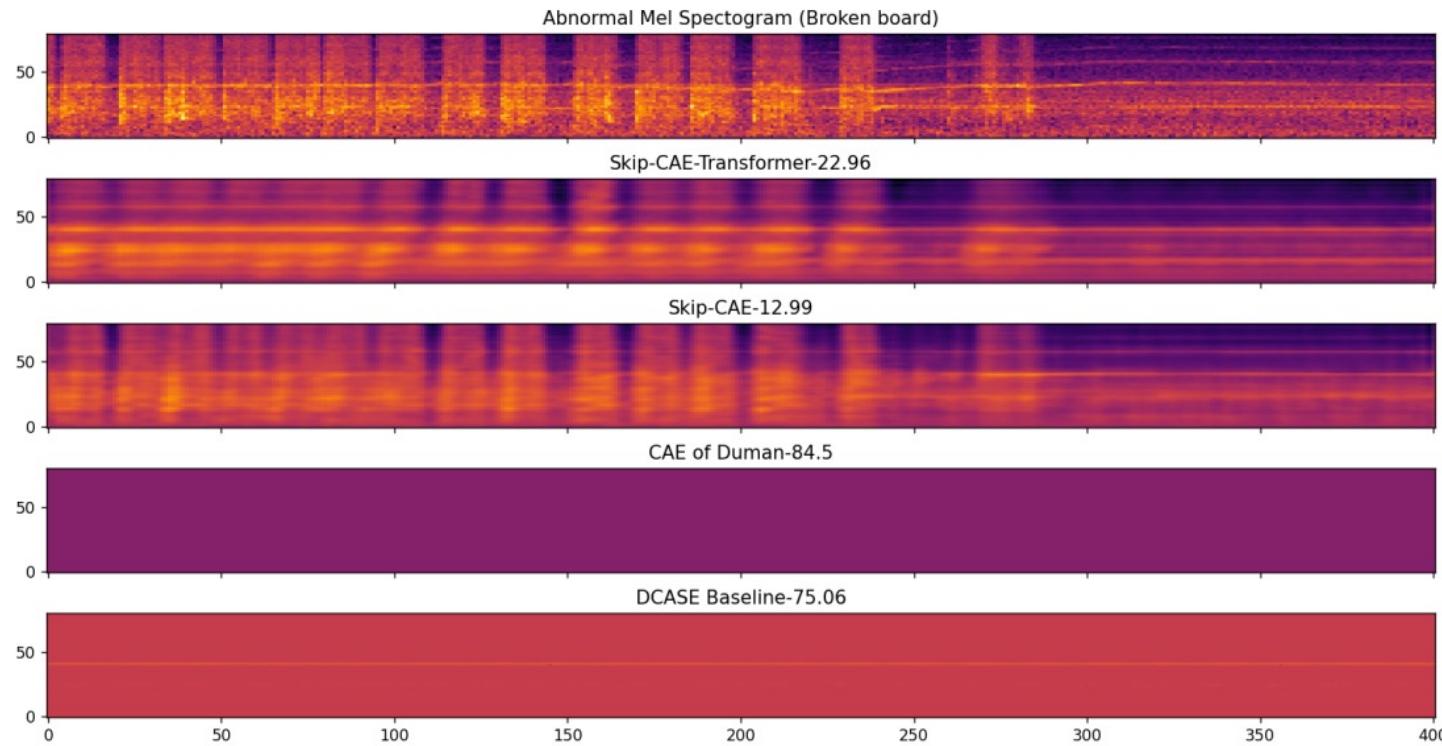
20



Reconstruction d'un réseau de neurones profond



Exemple de reconstruction pour un enregistrement abnormal

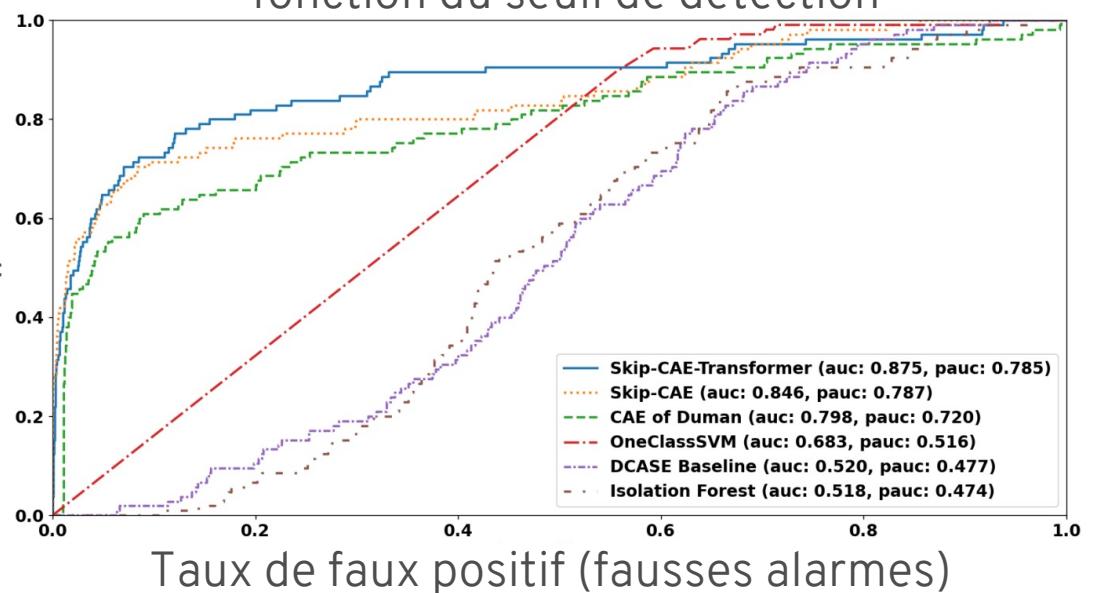


Résultats

- Notre réseau de neurones profond peut identifier environ 75 anomalies
 - Avec un taux de faux positif de 10%
 - 20 anomalies sans faux positif
 - AUC de 0.875
- Performe largement mieux que des approches classiques

Taux de vrai positif

Taux de faux positif et de vrai positif en fonction du seuil de détection



Résultats

TABLE II
AUC AND PAUC SCORE OF EACH MODEL FOR EACH ANOMALY TYPE

Model	Anomaly Type	Broken Board		Board Stuck		Uneven or Thick Wood	
		AUC	pAUC	AUC	pAUC	AUC	pAUC
Skip-CAE-Transformer		0.743	0.677	0.778	0.744	0.921	0.807
Skip-CAE		0.777	0.618	0.723	0.729	0.900	0.820
CAE of Duman <i>et al.</i> [2]		0.757	0.644	0.639	0.676	0.864	0.742
OneClassSVM		0.558	0.509	0.707	0.519	0.681	0.515
DCASE Baseline		0.441	0.474	0.620	0.480	0.484	0.476
Isolation Forest		0.437	0.474	0.613	0.474	0.485	0.474

[2] Duman, T. *et al.*. (2020). Acoustic anomaly detection using convolutional autoencoders in industrial processes

Conclusion

- Nous avons démontré qu'il est possible de détecter des problèmes grâce au son pour une raboteuse industrielle
 - AUC de 0.875
 - 20 anomalies détectées sans faux positif
- Nouveau jeu de données industriel public

Suite

- Stage de premier cycle cet été
 - Collecte de données en usine (Daaquam)
 - Ajout de capteurs
 - Prototypage
- Maîtrise par la suite
 - Mise en place des modèles dans une vraie usine
 - Comment gérer plusieurs capteurs?

